

Прогнозирование временных рядов

К. В. Воронцов vokov@forecsys.ru
А.А. Романенко alexromsput@gmail.com

30 Октября 2015

Содержание

1 Задачи прогнозирования

- Понятие временного ряда
- Обзор методов прогнозирования
- Напоминание с прошлого семестра

2 Адаптивные методы краткосрочного прогнозирования

- Модели типа ЭСС
- Модели с трендом и сезонностью
- Композиции адаптивных алгоритмов прогнозирования

3 Более сложные модели прогнозирования

- Регрессионные модели
- Эконометрические модели типа ARIMA
- Альтернативные методы прогнозирования

Временной ряд

$y_0, y_1, \dots, y_t, \dots$ — временной ряд, $y_i \in \mathbb{R}$


$\hat{y}_{t+d}(w) = f_t(y_1, \dots, y_t; w)$ — модель временного ряда,

где $d = 1, \dots, D$, D — горизонт (отсрочка, delay),

w — вектор параметров модели

Особенности задачи:

- количество временных рядов $10^6 - 10^8$;
- пропуски в данных;
- нестационарность (непостоянство модели);
- несимметричная, кусочно гладкая функция потерь.



Эконометрика — основной источник задач прогнозирования

Примеры эконометрических временных рядов:

- объёмы продаж в торговых сетях
- объёмы грузовых и пассажирских перевозок
- рыночные цены
- дорожный трафик (прогнозирование пробок)
- объёмы потребления и цены электроэнергии

Основные явления в эконометрических временных рядах:

- тренды
- сезонности
- разладки (смены модели ряда)

Марно Вербик. Путеводитель по современной эконометрике, 2008.

Пример. Задача прогнозирования объёмов продаж

Ежедневные объёмы продаж товара



Особенности задачи: целочисленные продажи, продажи зависят от типа товара, тренды, сезонность, пропуски, праздники, промо-акции, скачки, плохо работают сложные модели

Беглый обзор методов прогнозирования

- Методы прогнозирования типа ЭСС
- Адаптивная авторегрессия
- Авторегрессионные модели
- ARMA, ARIMA, GARCH,...
- Гусеница [Голяндина, 2003]
- Адаптивная селекция моделей
- Адаптивная композиция моделей
- Нейросетевые модели
- Прогнозирование разреженных временных рядов
- Прогнозирование при несимметричном функционале
- Прогнозирование плотности распределения

Простое экспоненциальное скользящее среднее

Линейная авторегрессионная модель данных:

$$y_{t+1} := \sum_{i=0}^t w_i y_i + \varepsilon_{t+1}$$

Прогнозная модель: $\hat{y}_{t+1} := \sum_{i=0}^t w_i y_i$

ε_{t+1} — непрогнозируемый шум, присутствующий в данных;

$e_{t+1} = y_{t+1} - \hat{y}_{t+1}$ — ошибка прогноза \hat{y}_{t+1} , сделанного на шаге t

Среднее арифметическое:

$$\hat{y}_{t+1} := \frac{1}{t+1} \sum_{i=0}^t y_i = \hat{y}_t + \frac{1}{t+1} (y_t - \hat{y}_t) = \hat{y}_t + \frac{1}{t+1} e_t$$

Скользящее среднее (СС):

$$\hat{y}_{t+1} := \alpha_t y_t + (1 - \alpha_t) \hat{y}_t = \hat{y}_t + \alpha_t (y_t - \hat{y}_t) = \hat{y}_t + \alpha_t \cdot e_t$$

При $\alpha_t = 1 - \frac{1}{t+1}$ имеем среднее арифметическое

При $\alpha_t = \text{const} \in (0, 1)$ имеем экспоненциальное СС

Адаптивная авторегрессионная модель

Линейная модель авторегрессии (линейный фильтр):

$$\hat{y}_{t+1}(\mathbf{w}) := \sum_{j=1}^n w_j y_{t-j+1}, \quad \mathbf{w} \in \mathbb{R}$$

Метод наименьших квадратов: $e_t^2 \rightarrow \min_w$.

Один шаг градиентного спуска в каждый момент t :

$$w_j := w_j + h_t e_t y_{t-j+1}.$$

Градиентный шаг в методе скорейшего спуска:

$$h_t = \frac{\alpha}{\sum_{j=1}^n y_{t-j+1}^2},$$

где α — аналог параметра сглаживания.

Подбор параметра сглаживания

Чем меньше α , тем больше вес последних точек,
при $\alpha \rightarrow 0$ тривиальный прогноз $\hat{y}_{t+1} = y_t$.

Чем больше α , тем сильнее сглаживание,
при $\alpha \rightarrow 1$ тривиальный прогноз $\hat{y}_{t+1} = \bar{y}$ (или скользящее среднее).

Оптимальное α^* находим по скользящему контролю:

$$Q(\alpha) = \sum_{t=T_0}^{T_1} (\hat{y}_t(\alpha) - y_t)^2 \rightarrow \min_{\alpha}$$

Эмпирические правила:

если $\alpha^* \in (0.7, 1)$, то ряд стационарен, ЭС работает;

если $\alpha^* \in (0, 0.7)$, то ряд нестационарен, нужна модель тренда.

Следящий контрольный сигнал

$e_t = y_t - \hat{y}_t$ — ошибка прогноза \hat{y}_t , сделанного на шаге $t - 1$
Следящий контрольный сигнал (tracking signal [Trigg, 1964])

$$K_t = \frac{\hat{e}_t}{\tilde{e}_t} \quad \begin{aligned} \hat{e}_{t+1} &:= \gamma e_t + (1 - \gamma) \hat{e}_t; \\ \tilde{e}_{t+1} &:= \gamma |e_t| + (1 - \gamma) \tilde{e}_t. \end{aligned}$$

Рекомендация: $\gamma = 0.05 \dots 0.1$

Статистический тест адекватности (при $\gamma \geq 0.1$, $t \rightarrow \infty$):

гипотеза $H_0: E\varepsilon_t = 0$, $E\varepsilon_t \varepsilon_{t+d} = 0$

принимается на уровне значимости δ , если

$$|K_t| \leq 1.2 \Phi_{1-\delta/2} \sqrt{1 - \gamma / (1 + \gamma)},$$


$\Phi_{1-\delta/2}$ — квантиль нормального распределения,

$\Phi_{1-\delta/2} = \Phi_{0.975} = 1.96$ при $\delta = 0.05$

Модель Тригга–Лича [Trigg, Leach, 1967]

Проблема: адаптивные модели плохо приспособляются к резким структурным изменениям

Решение: $\alpha = |K_t|$




Недостатки:

- 1) плохо реагирует на одиночные выбросы; ($\alpha_t = |K_{t-1}|$)
- 2) требует подбора γ , при рекомендации $\gamma = 0.05 \dots 0.1$.

Примеры трендов и сезонностей

Пример: сочетание тренда и сезонности (модельные данные)



Ряд 1 — сезонность без тренда

Ряд 2 — линейный тренд, аддитивная сезонность

Ряд 3 — линейный тренд, мультипликативная сезонность

Ряд 4 — экспоненциальный тренд, мультипликативная сезонность

Модель Хольта = линейный тренд

Линейный тренд без сезонных эффектов:

$$\hat{y}_{t+d} = a_t + b_t d,$$

где a_t , b_t — адаптивные коэффициенты линейного тренда

Рекуррентная формула:

$$a_t := \alpha_1 y_t + (1 - \alpha_1)(a_{t-1} + b_{t-1}) = \hat{y}_t + \alpha_1 e_t;$$

$$b_t := \alpha_2(a_t - a_{t-1}) + (1 - \alpha_2)b_{t-1} = b_{t-1} + \alpha_1 \alpha_2 e_t.$$

Частный случай — модель линейного роста Брауна:

$$\alpha_1 = 1 - \beta, \quad \alpha_2 = 1 - \beta \text{ (или } 1 + \beta).$$

Модель Уинтерса = мультипликативная сезонность

Мультипликативная сезонность периода s :

$$\hat{y}_{t+d} = a_t \cdot \theta_{t-s+(d \bmod s)},$$

$\theta_0, \dots, \theta_{s-1}$ — сезонный профиль периода s .

Рекуррентная формула:

$$a_t := \alpha_1(y_t/\theta_{t-s}) + (1 - \alpha_1)a_{t-1} = a_{t-1} + \alpha_1 e_t/\theta_{t-s};$$

$$\theta_t := \alpha_2(y_t/a_t) + (1 - \alpha_2)\theta_{t-s} = \theta_{t-s} + \alpha_2(1 - \alpha_1)e_t/a_t.$$

Доказательство последнего равенства:

$$\begin{aligned} \theta_t &:= \theta_{t-s} + \alpha_2(y_t/a_t - \theta_{t-s}) = \theta_{t-s} + \alpha_2(y_t - \theta_{t-s}a_t)/a_t = \\ &\theta_{t-s} + \alpha_2(y_t - \theta_{t-s}(a_{t-1} + \alpha_1 e_t/\theta_{t-s}))/a_t = \theta_{t-s} + \\ &+ \alpha_2 \left(\underbrace{y_t - \theta_{t-s}a_{t-1}}_{e_t} - \alpha_1 e_t \right) / a_t \end{aligned}$$

Модель Тейла–Вейджа

Линейный тренд с аддитивной сезонностью периода s :

$$\hat{y}_{t+d} = (a_t + b_t d) + \theta_{t+(d \bmod s)-s}.$$

$a_t + b_t d$ — тренд, очищенный от сезонных колебаний,
 $\theta_0, \dots, \theta_{s-1}$ — сезонный профиль периода s .

Рекуррентная формула:

$$a_t := \alpha_1(y_t - \theta_{t-s}) + (1 - \alpha_1)(a_{t-1} + b_{t-1}) = a_{t-1} + b_{t-1} + \alpha_1 e_t;$$

$$b_t := \alpha_2(a_t - a_{t-1}) + (1 - \alpha_2)b_{t-1} = b_{t-1} + \alpha_1 \alpha_2 e_t;$$

$$\theta_t := \alpha_3(y_t - a_t) + (1 - \alpha_3)\theta_{t-s} = \theta_{t-s} + \alpha_3(1 - \alpha_1)e_t.$$

Модель Уинтерса с линейным трендом

Мультипликативная сезонность периода s с линейным трендом:

$$\hat{y}_{t+d} = (a_t + b_t d) \cdot \theta_{t+(d \bmod s)-s},$$

$a_t + b_t d$ — тренд, очищенный от сезонных колебаний,
 $\theta_0, \dots, \theta_{s-1}$ — сезонный профиль периода s .

Рекуррентная формула:

$$a_t := \alpha_1(y_t/\theta_{t-s}) + (1 - \alpha_1)(a_{t-1} + b_{t-1}) = a_{t-1} + b_{t-1} + \alpha_1 e_t / \theta_{t-s};$$

$$b_t := \alpha_2(a_t - a_{t-1}) + (1 - \alpha_2)b_{t-1} = b_{t-1} + \alpha_1 \alpha_2 e_t / \theta_{t-s};$$

$$\theta_t := \alpha_3(y_t/a_t) + (1 - \alpha_3)\theta_{t-s} = \theta_{t-s} + \alpha_3(1 - \alpha_1)e_t/a_t.$$

Модель Уинтерса с экспоненциальным трендом

Мультипликативная сезонность с экспоненциальным трендом:

$$\hat{y}_{t+d} = a_t(r_t)^d \cdot \theta_{t+(d \bmod s)-s},$$

$a_t(r_t)^d$ — экспоненциальный тренд, очищенный от сезонности,
 $\theta_0, \dots, \theta_{s-1}$ — сезонный профиль периода s .

Рекуррентная формула:


$$a_t := \alpha_1(y_t/\theta_{t-s}) + (1 - \alpha_1)a_{t-1}r_{t-1} = a_{t-1}r_{t-1} + \alpha_1 e_t/\theta_{t-1};$$

$$r_t := \alpha_2(a_t/a_{t-1}) + (1 - \alpha_2)r_{t-1} = r_{t-1} + \alpha_1\alpha_2 e_t/\theta_{t-1};$$

$$\theta_t := \alpha_3(y_t/a_t) + (1 - \alpha_3)\theta_{t-s} = \theta_{t-s} + \alpha_3(1 - \alpha_1)e_t/a_t.$$

Пример

Динамика средних ошибок прогнозов для 6 моделей



AFTER [Yang Y., 2004]

ЛАВР, [Воронцов К.В., 2006]

Адаптивная селекция, [Лукашин, 2003; Timmermann, 2006]

Адаптивная композиция,

Агрегирующие алгоритмы [Вовк В., 1998].

Адаптивная селективная модель

Пусть имеется N моделей прогнозирования,
 $\hat{y}_{j,t+d}$ — прогноз j -й модели на момент $t+d$,
 $e_{jt} = y_t - \hat{y}_{jt}$ — ошибка прогноза в момент t ,
 $\tilde{e}_{jt} := \gamma |e_{jt}| + (1 - \gamma) \tilde{e}_{j(t-1)}$ — сглаженная ошибка.

Неотличимо лучшие модели в момент времени t для порога качества $e^* \geq 0$:

$$\Omega_t^* = \left\{ j \mid e_{jt} - \arg \min_{j=1, \dots, N} \tilde{e}_{jt} < e^* \right\}.$$

Адаптивная селективная модель:

$$\hat{y}_{j,t+d} := \frac{1}{|\Omega_t^*|} \sum_{j \in \Omega_t^*} \hat{y}_{j,t+d}$$

Требуется подбор γ , рекомендация: $\gamma = 0.01 \dots 0.1$.

Адаптивная композиция моделей

Пусть имеется N моделей прогнозирования,
 $\hat{y}_{j,t+d}$ — прогноз j -й модели на момент $t+d$,
 $e_{jt} = y_t - \hat{y}_{jt}$ — ошибка прогноза в момент t ,
 $\tilde{e}_{jt} := \gamma |e_{jt}| + (1 - \gamma) \tilde{e}_{jt}$ — экспоненциально сглаженная ошибка.

Линейная (выпуклая) комбинация моделей:

$$\hat{y}_{t+d} = \sum_{j=1}^N w_{jt} \hat{y}_{j,t+d}, \quad \sum_{j=1}^N w_{jt} = 1, \quad \forall t.$$

Адаптивный подбор весов [Лукашин, 2003]:

$$w_{jt} = \frac{(\tilde{e}_{jt})^{-1}}{\sum_{s=1}^N (\tilde{e}_{st})^{-1}}.$$

Требуется подбор γ , рекомендация: $\gamma = 0.01 \dots 0.1$.

Смешивание алгоритмов прогнозирования

Пусть имеется N моделей прогнозирования

$\lambda(y_t, \hat{y}_{j,t})$ — потери алгоритма j при прогнозе элемента y_t

$\mathcal{L}_j(T) = \sum_{t=1}^T \lambda(y_t, \hat{y}_{j,t})$ — суммарные потери алгоритма j к моменту времени T

\mathfrak{M} — искомая композиция

Найти \mathfrak{M} такую, что $\forall y_1, \dots, y_T,$

$$\mathcal{L}_{\mathfrak{M}}(T) \leq \arg \min_{j=\overline{1,N}} f(\mathcal{L}_j(T)),$$

где $f(x)$ — мало отличается от x .

Удаётся строить композиции с теоретическими гарантиями вида:

$$\mathcal{L}_{\mathfrak{M}}(T) \leq c \cdot \arg \min_{j=\overline{1,N}} \mathcal{L}_j(T) + a \ln(N).$$

Агрегирующий алгоритм В. Вовка

Прогнозы композиций AA_1 и AA_2

Инициализация: веса базовых алгоритмов $p_{j,0} = 1/N$

Для $t = 0, \dots, T - 1$


- 1 получить предсказания экспертов $\hat{y}_{j,t+1}, \forall j = \overline{1, N}$;
- 2 построить функцию смешивания:

$$g(x) = \log_{\beta} \left(\sum_{j=1}^N p_{j,t} \cdot \beta^{\lambda(y, \hat{y}_{j,t+1})} \right)$$

- 3 $\hat{y}_{AA_1, t+1} = \frac{Y_2 \sqrt{g(Y_1)} + Y_1 \sqrt{g(Y_2)}}{\sqrt{g(Y_1)} + \sqrt{g(Y_2)}};$
 $\hat{y}_{AA_2, t+1} = \frac{g(Y_1) - g(Y_2)}{2(Y_2 - Y_1)} + \frac{Y_1 + Y_2}{2};$
- 4 получить исход y_{t+1} ; вычислить ошибку $\lambda(y_{t+1}, \hat{y}_{t+1})$;
- 5 пересчитать веса экспертов $p_{j,t+1} = \beta^{\lambda(y_{t+1}, \hat{y}_{j,t+1})} \cdot p_{j,t}.$

Сравнение с базовыми алгоритмами

Эксперимент на реальных данных (1 из 1000 временных рядов)



$$\text{MSE} = \frac{1}{T} \sum_{t=1}^T e_t^2$$

Сравнение композиций

Таблица: Сравнение различных композиций, MSE


M	AFTER	AK	ЛАВР	AC	AA ₁	AA ₂
10	6,57	6,66	6,74	6,75	6,43	6,37
25	6,50	6,62	6,92	6,71	6,39	6,31
40	6,55	6,57	6,90	6,66	6,35	6,37
	100%	100%	105%	103%	95%	97%

Сравнение с базовыми алгоритмами (BE - лучший из базовых алгоритмов, ТВ - теоретическая оценка ошибки):

	1	2	5	10	15	20
AA ₁	21.69	32.24	57.33	94.17	110.4	139.9
BE	22.05	32.63	58.24	95.23	111.5	140.6
ТВ	25.16	38.2	71.80	99.44	141.1	179.7

Авторегрессионная модель

Почасовые цены электроэнергии на бирже NordPool, 2000г.



Особенности задачи: три вложенные сезонности, скачки

Линейная модель авторегрессии

В роли признаков — n предыдущих наблюдений ряда:

$$\hat{y}_{t+1}(w) = \sum_{j=1}^n w_j y_{t-j+1}, \quad w \in \mathbb{R}^n$$

В роли объектов $\ell = t - n + 1$ моментов в истории ряда:

$$F_{\ell \times n} = \begin{pmatrix} y_t & y_{t-1} & y_{t-2} & \cdots & y_{t-n+1} \\ y_{t-1} & y_{t-2} & y_{t-3} & \cdots & y_{t-n} \\ y_{t-2} & y_{t-3} & y_{t-4} & \cdots & y_{t-n-1} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ y_n & y_{n-1} & y_{n-2} & \cdots & y_1 \end{pmatrix}, \quad y_{\ell \times 1} = \begin{pmatrix} y_{t+1} \\ y_t \\ y_{t-1} \\ \cdots \\ y_{n+1} \end{pmatrix}$$

Функционал квадрата ошибки:

$$Q_t(w, X^\ell) = \sum_{i=n+1}^{t+1} (\hat{y}_i(w) - y_i)^2 = \|Fw - y\|^2 \rightarrow \min_w$$

Модель ARMA

ARMA(p,q): y_1, \dots, y_t

- $$y_t = c + \underbrace{\sum_{i=1}^p \alpha_i y_{t-i}}_{AR} + \underbrace{\sum_{j=1}^q \beta_j \varepsilon_{t-j}}_{MA} + \varepsilon_t;$$
- $L : Ly_t = y_{t-1}$ — лаговый оператор;
 $L^i : L^i y_t = L^{i-1}(Ly_t) = y_{t-i};$
- $(1 - \sum_{i=1}^p \alpha_i L^i) y_t = c + (1 + \sum_{j=1}^q \beta_j L^j) \varepsilon_t;$

$$y_t = \mu + \frac{F(L)}{H(L)} \varepsilon_t \text{ — каноническая запись ARMA}$$

$F(L) = (1 + \sum_{j=1}^q \beta_j L^j)$ — оператор скользящего среднего;

$H(L) = (1 - \sum_{i=1}^p \alpha_i L^i)$ — оператор авторегрессии;

ε_t — случайная компонента, $E\varepsilon_t = 0, E\varepsilon_i \varepsilon_j = 0$

Ряд y_t является стационарным, если корни $H(z) = 0$ лежат вне единичного круга комплексной плоскости.

Модель ARIMA

y_t — **НЕ**стационарный, т.е. $H(z)$ — имеет d единичных корней;

- $H(L) = (1 - \sum_{i=1}^p \alpha_i L^i) = (1 - \sum_{i=1}^{\tilde{p}} \alpha_i L^i)(1 - L)^d$
- $(1 - \sum_{i=1}^{\tilde{p}} \alpha_i L^i)(1 - L)^d y_t = c + (1 + \sum_{j=1}^q \beta_j L^j) \varepsilon_t$

$$z_t = (1-L)^d y_t = \mu + \frac{F(L)}{H(L)} \varepsilon_t \text{ — каноническая запись ARIMA}(p, q, d)$$


Можно также выписывать аналог для сезонных временных рядов $\text{ARIMA}(p, q, d) \times (P, Q, D)_s$:

$$(1 - L)^d (1 - L^s)^D y_t = \mu + \frac{F(L)}{H(L)} \frac{(1 + \sum_{j=1}^Q \gamma_j L^{s \cdot j})}{(1 - \sum_{i=1}^P \delta_i L^{s \cdot i})} \varepsilon_t$$

Модель ARIMAX

y_t — нестационарный, X_t — вектор регрессоров из \mathbb{R}^N ,
известный до начала момента прогнозирования;
ARIMAX(p,q,d):

$$z_t = \mu + \sum_{n=1}^N \frac{v_n(L)}{u_n(L)} X_{n,t} + \frac{F(L)}{H(L)} \varepsilon_t$$



Pro&Cons ARIMA


Заключение по ARIMA–моделям

- обобщают модели а-ля ЭСС ($\text{ЭСС} = \text{ARIMA}(0,1,1)$ при $\mu = 0$)
- позволяют учитывать внешние факторы (акции, скачки цен, температуру и т.д.)
- не работает при наличии пропусков в данных;
- тяжело обучить (на практике используют перебор $p, q, d = \overline{0, 3}$;
- методы обучения опираются на нормальность ε_t
 - не для всех временных рядов удаётся найти соответствующую модель;
 - плохо работает на разреженных и коротких временных рядах;

Box, G. E. P. – Jenkins, G. M. – Reinsel, G. C.: Time Series Analysis: Forecasting and Control. John Wiley & Sons Inc., New York, 2008

Зачем нужно что-то ещё более сложное?

Прогнозирование объёмов электроэнергии



Резюме в конце лекции

- Адаптивные методы хорошо работают, когда рядов много, и прогнозировать их надо быстро
- Простота адаптивных методов компенсируется селективными и композиционными моделями
- При этом различные особенности рядов моделируются в базовых алгоритмах
- Для временных рядов со сложной структурой можно использовать более сложные алгоритмы

Лукашин Ю. П. Адаптивные методы краткосрочного прогнозирования временных рядов. Финансы и статистика, 2003.