

# Метрические методы классификации

К. В. Воронцов, А. В. Зухба

`vokov@forecsys.ru`

`a_l@mail.ru`

февраль 2015

## Содержание

- 1 **Метрические алгоритмы классификации**
  - Гипотеза компактности
  - Метод ближайших соседей и его обобщения
  - Метод парзеновского окна
  - Метод потенциальных функций
- 2 **Отбор эталонов и оптимизация метрики**
  - Понятие отступа
  - Алгоритм отбора эталонных объектов STOLP
- 3 **Профиль компактности и скользящий контроль**
  - Полный скользящий контроль CCV
  - Понятие профиля компактности
  - Отбор эталонов по функционалу CCV

## Гипотеза компактности

### Задача классификации:

$X$  — объекты,  $Y$  — ответы (идентификаторы классов);

$X^\ell = (x_i, y_i)_{i=1}^\ell$  — обучающая выборка;

### Гипотеза компактности:

Схожие объекты, как правило, лежат в одном классе.

### Формализация понятия «сходства»:

Задана функция расстояния  $\rho: X \times X \rightarrow [0, \infty)$ .


Например, евклидово расстояние:

$$\rho(u, x_i) = \left( \sum_{j=1}^n |u^j - x_i^j|^2 \right)^{1/2},$$

где  $u = (u^1, \dots, u^n)$ ,  $x_i = (x_i^1, \dots, x_i^n)$  — признаковые описания объектов.

## Пример: задача классификации цветков ириса [Фишер, 1936]

$n = 4$  признака,  $|Y| = 3$  класса, длина выборки  $\ell = 150$ .



## Обобщённый метрический классификатор

Для произвольного  $u \in X$  отсортируем объекты  $x_1, \dots, x_\ell$ :

$$\rho(u, x_u^{(1)}) \leq \rho(u, x_u^{(2)}) \leq \dots \leq \rho(u, x_u^{(\ell)}),$$

$x_u^{(i)}$  —  $i$ -й сосед объекта  $u$  среди  $x_1, \dots, x_\ell$ ;

$y_u^{(i)}$  — ответ на  $i$ -м соседе объекта  $u$ .

**Метрический алгоритм классификации:**

$$a(u; X^\ell) = \arg \max_{y \in Y} \underbrace{\sum_{i=1}^{\ell} [y_u^{(i)} = y] w(i, u)}_{\Gamma_y(u, X^\ell)},$$

$w(i, u)$  — вес (степень важности)  $i$ -го соседа объекта  $u$ ,  
неотрицателен, не возрастает по  $i$ .

$\Gamma_y(u, X^\ell)$  — оценка близости объекта  $u$  к классу  $y$ .

## Метод ближайшего соседа

$$w(i, u) = [i=1].$$

### Преимущества:

- простота реализации;
- интерпретируемость решений,  
вывод на основе прецедентов (case-based reasoning, CBR)

### Недостатки:

- неустойчивость к погрешностям (шуму, выбросам);
- отсутствие настраиваемых параметров;
- низкое качество классификации;
- приходится хранить всю выборку целиком.

## Метод $k$ ближайших соседей

$$w(i, u) = [i \leq k].$$

### Преимущества:

- менее чувствителен к шуму;
- появился параметр  $k$ .

### Оптимизация числа соседей $k$ :

функционал скользящего контроля leave-one-out

$$\text{LOO}(k, X^\ell) = \sum_{i=1}^{\ell} \left[ a(x_i; X^\ell \setminus \{x_i\}, k) \neq y_i \right] \rightarrow \min_k.$$

### Проблема:

- неоднозначность классификации  
при  $\Gamma_y(u, X^\ell) = \Gamma_s(u, X^\ell)$ ,  $y \neq s$ .

## Пример зависимости $LOO(k)$

### Пример. Задача UCI: Breast Cancer (Wisconsin)



- смещённое число ошибок, когда объект учитывается как сосед самого себя
- несмещённое число ошибок  $LOO$

В реальных задачах минимум редко бывает при  $k = 1$ .



## Метод $k$ взвешенных ближайших соседей

$$w(i, u) = [i \leq k] w_i,$$

где  $w_i$  — вес, зависящий только от номера соседа;

**Возможные эвристики:**

$w_i = \frac{k+1-i}{k}$  — линейные убывающие веса;

$w_i = q^i$  — экспоненциально убывающие веса,  $0 < q < 1$ ;

**Проблемы:**

- как более обоснованно задать веса?
- возможно, было бы лучше, если бы вес  $w(i, u)$  зависел не от порядкового номера соседа  $i$ , а от расстояния до него  $\rho(u, x_u^{(i)})$ .

## Метод парзенковского окна

$$w(i, u) = K\left(\frac{\rho(u, x_u^{(i)})}{h}\right),$$

где  $K(r)$  — ядро, невозрастающее, положительное на  $[0, 1]$ .


Метод парзенковского окна фиксированной ширины:

$$a(u; X^\ell, \textcolor{red}{h}, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_u^{(i)} = y] \underbrace{K\left(\frac{\rho(u, x_u^{(i)})}{\textcolor{red}{h}}\right)}_{w(i, u)}.$$

Метод парзенковского окна переменной ширины:

$$a(u; X^\ell, \textcolor{red}{k}, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_u^{(i)} = y] \underbrace{K\left(\frac{\rho(u, x_u^{(i)})}{\rho(u, x_u^{(\textcolor{red}{k}+1)})}\right)}_{w(i, u)}.$$

## Часто используемые ядра



$E(r) = \frac{3}{4}(1 - r^2)[|r| \leq 1]$  — оптимальное (Епанечникова);

$Q(r) = \frac{15}{16}(1 - r^2)^2[|r| \leq 1]$  — кватрическое;

$T(r) = (1 - |r|)[|r| \leq 1]$  — треугольное;

$G(r) = (2\pi)^{-1/2} \exp(-\frac{1}{2}r^2)$  — гауссовское;

$\Pi(r) = \frac{1}{2}[|r| \leq 1]$  — прямоугольное.

## Метод потенциальных функций

$$w(i, u) = \gamma_u^{(i)} K\left(\frac{\rho(u, x_u^{(i)})}{h_u^{(i)}}\right)$$

Более простая запись:

$$a(u; X^\ell) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_i = y] \gamma_i K\left(\frac{\rho(u, x_i)}{h_i}\right),$$

где  $\gamma_i$  — веса объектов,  $\gamma_i \geq 0$ ,  $h_i > 0$ .

**Физическая аналогия:**

$\gamma_i$  — величина «заряда» в точке  $x_i$ ;

$h_i$  — «радиус действия» потенциала с центром в точке  $x_i$ ;

$y_i$  — знак «заряда» (предполагается, что  $Y = \{-1, +1\}$ );

в электростатике  $K(r) = \frac{1}{r}$  или  $\frac{1}{r+a}$ .

## Алгоритм настройки весов объектов

Простой эвристический алгоритм настройки  $\gamma_i$ .

---

**Вход:**

$X^\ell$  — обучающая выборка;

**Выход:**

Коэффициенты  $\gamma_i$ ,  $i = 1, \dots, \ell$ ;

---

- 1: Инициализация:  $\gamma_i = 0$  для всех  $i = 1, \dots, \ell$ ;
- 2: **повторять**
- 3:   выбрать объект  $x_i \in X^\ell$ ;
- 4:   **если**  $a(x_i) \neq y_i$  **то**
- 5:      $\gamma_i := \gamma_i + 1$ ;
- 6: **пока** число ошибок на выборке  $Q(a, X^\ell) > \varepsilon$ .

## Анализ преимуществ и недостатков

### Преимущества:

- простота реализации;
- не надо хранить выборку (поточковый алгоритм обучения);
- разреженность: не все обучающие объекты учитываются.

### Недостатки:

- медленная сходимость;
- результат обучения зависит от порядка просмотра объектов;
- слишком грубо настраиваются веса  $\gamma_i$ ;
- вообще не настраиваются параметры  $h_i$ ;
- вообще не настраиваются центры потенциалов;
- может, некоторые  $\gamma_i$  можно было бы обнулить?

## Понятие отступа

Рассмотрим классификатор  $a: X \rightarrow Y$  вида

$$a(u) = \arg \max_{y \in Y} \Gamma_y(u), \quad u \in X.$$


Отступом (margin) объекта  $x_i \in X^\ell$  относительно классификатора  $a(u)$  называется величина

$$M(x_i) = \Gamma_{y_i}(x_i) - \max_{y \in Y \setminus y_i} \Gamma_y(x_i).$$

- Отступ показывает *степень типичности* объекта:  
чем больше  $M(x_i)$ , тем «глубже»  $x_i$  в своём классе;
- $M(x_i) < 0 \Leftrightarrow a(x_i) \neq y_i$ ;

## Типы объектов, в зависимости от отступа

- Э — *эталонные* (можно оставить только их);
- Н — *неинформативные* (можно удалить из выборки);
- П — *пограничные* (их классификация неустойчива);
- О — *ошибочные* (причина ошибки — плохая модель);
- Ш — *шумовые* (причина ошибки — плохие данные).





## Отбор эталонов (prototype selection)

**Задача:** выбрать оптимальное подмножество эталонов  $\Omega \subseteq X^\ell$

Классификатор будет иметь вид:

$$a(u; \Omega) = \arg \max_{y \in Y} \sum_{x_i \in \Omega} [y_u^{(i)} = y] w(i, u),$$

$x_u^{(i)}$  —  $i$ -й сосед объекта  $u$  среди  $\Omega$ ;

$y_u^{(i)}$  — ответ на  $i$ -м соседе объекта  $u$ ;

$w(i, u)$  — произвольная функция веса  $i$ -го соседа.

**Алгоритм STOLP:**

- ❶ исключить выбросы и, возможно, пограничные объекты;
- ❷ найти по одному эталону в каждом классе;
- ❸ добавлять эталоны, пока есть отрицательные отступы;

## Алгоритм STOLP

**Вход:**  $X^\ell$ ; параметры  $\delta, \ell_0$ ;

**Выход:** Множество опорных объектов  $\Omega \subseteq X^\ell$ ;

- 
- 1: **для всех**  $x_i \in X^\ell$  проверить, является ли  $x_i$  выбросом:
  - 2:   **если**  $M(x_i, X^\ell) < \delta$  **то**
  - 3:      $X^{\ell-1} := X^\ell \setminus \{x_i\}$ ;    $\ell := \ell - 1$ ;
  - 4: Инициализация: взять по одному эталону от каждого класса:  
    $\Omega := \{\arg \max_{x_i \in X_y^\ell} M(x_i, X^\ell) \mid y \in Y\}$ ;
  - 5: **пока**  $\Omega \neq X^\ell$ ;
  - 6:   Выделить множество объектов с ошибкой  $a(u; \Omega)$ :  
    $E := \{x_i \in X^\ell \setminus \Omega : M(x_i, \Omega) < 0\}$ ;
  - 7:   **если**  $|E| < \ell_0$  **то выход**;
  - 8:   Присоединить к  $\Omega$  объект с наименьшим отступом:  
    $x_i := \arg \min_{x \in E} M(x, \Omega)$ ;    $\Omega := \Omega \cup \{x_i\}$ ;

## Алгоритм STOLP: преимущества и недостатки

### Преимущества отбора эталонов:

- сокращается число хранимых объектов;
- сокращается время классификации;
- объекты распределяются по величине отступов;

### Недостатки алгоритма STOLP:

- необходимость задавать параметр  $\delta$ ;
- относительно низкая эффективность  $O(|\Omega|^2 \ell)$ .

### Другие методы отбора:

- стратегия последовательного удаления не-эталонов;
- минимизация полного скользящего контроля (CCV);
- FRiS-STOLP на основе оценок *конкурентного сходства*.

## Полный скользящий контроль CCV

Функционал *полного* скользящего контроля  
(complete cross-validation, CCV):

$$\text{CCV}(X^L) = \frac{1}{C_L^\ell} \sum_{X^\ell \sqcup X^k} \frac{1}{k} \sum_{x_i \in X^k} [a(x_i, X^\ell) \neq y_i],$$

где  $X^\ell \sqcup X^k$  — все  $C_L^\ell$  разбиений выборки  $X^L$  на обучающую подвыборку  $X^\ell$  и контрольную  $X^k$ .

**Замечание 1.** При  $k = 1$  имеем:  $\text{CCV}(X^L) = \text{LOO}(X^L)$ .

**Замечание 2.** CCV характеризует лишь среднюю частоту ошибок, но не учитывает её разброс.

## Понятие профиля компактности

### Определение

Профиль компактности выборки  $X^L$  — это функция доли объектов  $x_i$ , у которых  $m$ -й сосед  $x_i^{(m)}$  лежит в другом классе:

$$K(m, X^L) = \frac{1}{L} \sum_{i=1}^L [y_i \neq y_i^{(m)}]; \quad m = 1, \dots, L-1,$$

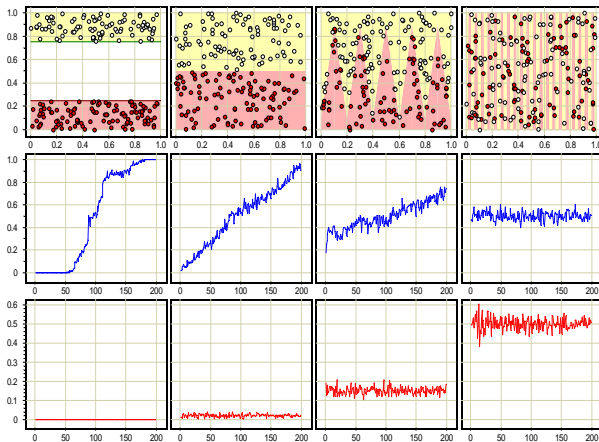
где  $x_i^{(m)}$  —  $m$ -й сосед объекта  $x_i$  среди  $X^L$ ;

$y_i^{(m)}$  — ответ на  $m$ -м соседе объекта  $x_i$ .

### Теорема (точное выражение CCV для метода 1NN)

$$\text{CCV}(X^L) = \sum_{m=1}^k K(m, X^L) \frac{C_{L-1-m}^{\ell-1}}{C_{L-1}^{\ell}}.$$

## Профили компактности для серии модельных задач




средний ряд: профили компактности,  
нижний ряд: зависимость CCV от длины контроля  $k$ .

## Свойства профиля компактности и оценки CCV

$$\text{CCV}(X^L) = \sum_{m=1}^k K(m, X^L) \frac{C_{L-1-m}^{\ell-1}}{C_{L-1}^{\ell}}.$$

- $K(m, X^L)$  формализует гипотезу компактности, связывая свойства выборки с качеством классификации.
- CCV практически не зависит от длины контроля  $k$ .
- Для минимизации CCV важен только начальный участок профиля, т. к.  $\frac{C_{L-1-m}^{\ell-1}}{C_{L-1}^{\ell}} \rightarrow 0$  экспоненциально по  $m$ .
- Минимизация CCV позволяет делать отбор эталонов.


## Модельные данные




Модельная задача классификации: 1000 объектов.  
Алгоритм 1NN



## Последовательное добавление эталонных объектов




## Последовательный отсев не-эталонных объектов



## Последовательный отсев не-эталонных объектов

Зависимость CCV от числа удаленных неэталонных объектов.



При отборе эталонов по критерию CCV переобучения нет.

## Резюме в конце лекции

- Метрические классификаторы — одни из самых простых. Качество классификации определяется качеством метрики.
- Что можно обучать:
  - число ближайших соседей  $k$ ;
  - набор эталонов (prototype selection);
  - как вариант — веса объектов;
  - метрику (distance learning, similarity learning);
  - как частный случай — веса признаков.
- *Распределение отступов* делит объекты на эталонные, неинформативные, пограничные, ошибки и выбросы.
- *Профиль компактности* выборки позволяет судить о том, насколько удачно метрика подобрана под задачу.