

Теоретические задачи

3.1 Линейный классификатор

① $X = \mathbb{R}^d$ - пр-во объектов

$Y = \{-1, 1\}$ - мн-во допустимых ответов

$X = \{(x_i, y_i)\}_{i=1}^{\ell}$ - обучающая выборка дискриминантная

Лин. модель: $a(x) = \text{sign}(\langle w, x \rangle + w_0) =$
 $= \text{sign}\left(\sum_{j=1}^d w_j x_j + w_0\right)$

Геом. смысл: гиперплоскость с вектором нормали w .

$\langle w, x \rangle$ - расстояние от гиперплоскости до x
знак - с какой стороны от гиперплоскости находится данная точка

② Введем функционал ошибки:

$$Q(\alpha, X) = \frac{1}{2} \sum_{i=1}^{\ell} [\text{sign}(\langle w, x_i \rangle) \neq y_i] \rightarrow \min$$

Функционал дискретен отн весов \Rightarrow
минимизацию искать с помощью
градиентного спуска невозможно.

Также может быть много минимумов

$$\Rightarrow Q(\alpha, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \underbrace{[y_i \langle w, x_i \rangle < 0]}_{M_i} \rightarrow \min$$

$M_i = y_i \langle w, x_i \rangle$ - отступ

знак: корректность ответа классификатора
абс. величина: степень уверенности классификатора в ответе

③ Введем константный признак $x_0 = 1$,
а к вектору весов w_0 .

④ $\tilde{Q}(w) = \sum_{i=1}^l \underbrace{[M_i(w)]_+}_{\text{функция потерь}} \rightarrow \min_w$ - функционал

минимизации риска.
Для минимизирующего алгоритма класс принимает 0.

⑤ $\tilde{Q}(w) = \sum_{i=1}^l [M_i < 0] \rightarrow \min_w$

при $w=0$.

⑥ ~~Функция потерь~~. $Q(a, x) = \frac{1}{l} \sum_{i=1}^l L(M)$


⑦ Ф-ция потерь - способ измерения ошибки
Алгоритма

Для лм классиф.


$Q(a, x) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i]$

Обычно выпуклая,
в св-ве линейной
классификации,
невозрастающая

Пороговая ф.п



⑧ Экспоненц. ф.п



Логистическая



8) Неправильная ф-я потерь - пороговая
ф-я потерь $L(M) = [M \leq 0]$

9) Регуляризация - способ борьбы с переобучением, штраф за сложность
Идеа: добавление некоторой ф-ии в минимизируемую ф-ию.

$$Q(w, x) + \lambda \underbrace{\|w\|^2}_{\text{коэффициент регуляризации}} \rightarrow \min$$

• L_1 -регуляризатор: $\|w\|_1 = \sum |w_j|$

• L_2 -регуляризатор: $\|w\|_2 = \sqrt{\sum w_j^2}$

10) Переобучение - алгоритм запоминание
под объектами обучающей выборки

При попытке обобщения алгоритма на
новые данные, показ-ся плохой результат.

Регуляризация - способ ~~с~~ борьбы с
переобучением \Rightarrow

повышение обобщающей способности
алгоритма

11) Эмпирический риск - средняя величина
ошибки алгоритма на обучающей выборке

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l L(a, x_i) - \text{функционал}$$

т.к. вычисл-ся по эмпирическим данным

Метод минимизирующий эмпирический риск,
может получить обучающую выборку, запо-
нить её и строить алгоритм, который
сравнивает предъявляемый объект с обучающим.
Такой алгоритм не способен восстановить зависимость
все материалы обучения. \Rightarrow переобучение

При отступе от точки минимума, значение функционала аппроксимированного эмпирического риска сильно возрастает

(12) Если параметр выходит из допустимых значений \Rightarrow регуляризация увеличивает зн-ие эмпр. риск.

(13) Регуляризация влияет на значение функционала (увеличивает) \Rightarrow с регуляризацией.

(14) С одной стороны, без регуляризации, т.к. без неё происходит переобучение, и сред-но, такие результаты.

С другой стороны, с регуляризацией, при среднем, когда даже значение с переобучением было меньше, тем если от нас ~~добавить~~ добавили регуляризатор

(15) Есть бинарная классификация:
 $y = 1$ $y = -1$ — ответ
 — ответ
 — ответ

$1 = a(x)$

$-1 = a(x)$

ответ
системы

True Positive (TP)	False Positive (FP)
False Negative (FN)	True Negative (TN)

TP, FN, FP, TN — кол-во объектов

$$Accuracy = \frac{TP + TN}{X_1 + X_{-1}}$$

где X_1 — кол-во объектов
 класса $\{1\}$,
 аналогично X_{-1}

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{P}$$

①⑥ Пусть $FPR = \frac{FP}{X_{-1}}$ - False Positive Rate

$$TPR = \frac{TP}{X_1} - \text{True " - "}$$

ROC-кривая - кривая точности-полноты
т.е. зависимость TPR (FPR) - доли верных
положительных классификаций, от доли ложных положительных
Аус-метрика - площадь под ROC-кривой

①⑦ Дано: выборка
ф-ция: $f(x, w)$ - дискриминантная

Выход: $\{(FPR_i, TPR_i)\}_{i=0}^m$ - набор точек
ROC-кривой

Алгоритм:

1) Вычислить представит. классы:

m_- и m_+

2) Упорядочим выборку x по убыванию
зн-ий $f(x_i, w)$

3) $(0, 0)$ - изначальная точка ROC-кривой

4) $\forall i = 1..m$:

~~если~~ если m_- , то сместиться на 1
шаг вправо

~~$$FPR_i = FPR_{i-1} + \frac{1}{m_-}$$~~

$$(TPR_i, FPR_i) = (TPR_{i-1}, FPR_{i-1} + \frac{1}{m_-})$$

• иначе сместиться вверх

$$(TPR_i, FPR_i) = (TPR_{i-1} + \frac{1}{m_+}, FPR_i)$$

№3.2. Вероятностный смысл рекурризаторов

Введем вероятностное пространство и совместную плотность распределения объектов и классов $p(x, y | \omega)$

γ -гиперпараметр ω - параметры модели

Введем априорную плотность $p_\gamma(\omega)$.

Запишем ф-ию правдоподобия выборки X и модели

$$F_\gamma(\omega, X) = \ln \cdot \Phi_\gamma(\omega, X) = \\ = \sum_{i=1}^l \ln p(x_i, y_i | \omega) + \ln p_\gamma(\omega) \rightarrow \max$$

Минимизация потерь аппроксимированного эмпирического риска эквивалентна максимизации правдоподобия:

$$Q(\omega, X) = \sum_{i=1}^l \ln p(x_i, y_i | \omega) + \ln p_\gamma(\omega) = \\ \left| \begin{aligned} &= \sum \ln p(x_i, y_i | \omega) = \sum L(y, f) \\ &= \ln p_\gamma(\omega) = \gamma \cdot V - \text{рекурризатор} \end{aligned} \right| = \\ = \sum L(y, f) + \gamma \cdot V$$

\Rightarrow рекурризатор имеет априорное распределение некоторой системы плотностей.

ℓ_1 : распределение Лапласа

ℓ_2 : n -мерное гауссовское

§ 3.4 Kernel trick

Рассмотрим следующее ядро:

$$K(x, y) = \langle x, y \rangle^2 = x_1^2 y_1^2 + 2x_1 y_1 x_2 y_2 + x_2^2 y_2^2 = \\ = \langle (x_1^2, x_2^2, \sqrt{2}x_1 x_2, y_1^2, y_2^2, \sqrt{2}y_1 y_2) \rangle$$

\Rightarrow ~~размерность~~ размерность: $\mathbb{R}^3 \Rightarrow$

отображение: $(x_1, x_2) \rightarrow (x_1^2, x_2^2, \sqrt{2}x_1 x_2)$

Из условия: разделяющая поверхность имеет координаты: $w = (1, 2, 0)$, $w_0 = -3$

$$(x_1, x_2, \sqrt{2}x_1 x_2) \cdot (1, 2, 0) + w_0 = x_1^2 + 2x_2^2 - 3 = 0$$

Как в условии

§ 3.3 SVM и максимизация разделяющей полосы

$$a(x) = \text{sign}(\langle w, x \rangle - w_0)$$